

au service de la cybersécurité

Applications, avantages, limites, nouveaux risques et perspectives

Question de recherche

Comment l'intelligence artificielle transforme-t-elle la détection et la prévention des cybermenaces, et quelles sont les limites et les nouveaux risques liés à son utilisation en cybersécurité ?

Auteur Judicaël OUEDRAOGO

Date 29 septembre 2026

Nature Rapport de recherche documentaire et analytique

Document préparé selon des principes de traçabilité scientifique, de prudence méthodologique et de reproductibilité.

Résumé

Cette étude analyse l'utilisation de l'intelligence artificielle (IA) en cybersécurité, en particulier pour la détection d'intrusions, la détection de logiciels malveillants, la détection du phishing, l'analyse comportementale, l'assistance aux centres opérationnels de sécurité (SOC), l'exploitation des SIEM et la threat intelligence. Elle examine simultanément les limites et les risques associés aux systèmes de sécurité fondés sur l'IA : qualité des données, déséquilibre des classes, faux positifs et faux négatifs, explicabilité, généralisation, biais, attaques adversariales, empoisonnement des données, confidentialité et sécurité des modèles.

Le travail adopte une approche documentaire et analytique. Les résultats quantitatifs sont présentés comme des résultats propres aux études et protocoles considérés, et non comme des performances universelles. Pour chaque résultat, l'étude, l'année, le jeu de données, la tâche, le modèle, la métrique et les limites sont identifiés lorsque l'information est disponible. Cette précaution est essentielle : une précision élevée obtenue sur un benchmark ne démontre pas, à elle seule, une efficacité équivalente dans un environnement opérationnel différent. Les publications consultées confirment également une double dynamique : l'IA peut renforcer la défense, mais les systèmes d'IA constituent eux-mêmes des actifs à sécuriser. Les travaux de NIST et d'ENISA insistent notamment sur la gestion du risque, la robustesse, la traçabilité, les attaques adversariales et la nécessité de sécuriser l'ensemble du cycle de vie des systèmes d'IA [5, 6, 14, 16].

La conclusion centrale est donc structurée autour de deux dimensions complémentaires : **AI for Security**, c'est-à-dire l'utilisation de l'IA pour renforcer la cybersécurité, et **Security for AI**, c'est-à-dire la sécurisation des données, modèles, infrastructures et usages de l'IA.

Mots-clés

Intelligence artificielle ; cybersécurité ; machine learning ; deep learning ; détection d'intrusion ; détection de malware ; phishing ; analyse comportementale ; apprentissage adversarial ; SOC ; SIEM ; threat intelligence.

Table des matières

Résumé	i
Mots-clés	i
1 Introduction et cadre de recherche	1
1.1 Contexte	1
1.2 Problématique	1
1.3 Objectifs	2
1.3.1 Objectif général	2
1.3.2 Objectifs spécifiques	2
1.4 Questions de recherche	2
1.5 Périmètre et méthode	2
2 Fondements de l'IA et de la cybersécurité	3
2.1 Intelligence artificielle	3
2.2 Apprentissage automatique	3
2.2.1 Apprentissage supervisé	3
2.2.2 Apprentissage non supervisé et détection d'anomalies	3
2.2.3 Classification et détection d'anomalies	3
2.3 Deep learning	4
2.4 IA générative	4
2.5 Notions fondamentales de cybersécurité	4
3 Applications de l'IA en cybersécurité	5
3.1 Détection d'intrusion	5
3.2 Détection de malware	5
3.3 Détection du phishing	5
3.4 Analyse comportementale	6
3.5 SOC et SIEM	6
3.6 Threat intelligence	6
4 Bénéfices de l'IA en cybersécurité	8
4.1 Automatisation	8

4.2	Scalabilité	8
4.3	Vitesse de détection	8
4.4	Reconnaissance de motifs	8
4.5	Détection d'anomalies	8
4.6	Priorisation des alertes	9
4.7	Surveillance continue et assistance aux analystes	9
5	Limites et risques	10
5.1	Faux positifs	10
5.2	Faux négatifs	10
5.3	Qualité des données	10
5.4	Généralisation	10
5.5	Explicabilité	11
5.6	Biais	11
5.7	Apprentissage automatique adversarial	11
5.7.1	Évasion	11
5.7.2	Poisoning	11
5.7.3	Attaques de confidentialité et manipulation de modèle	11
5.8	Confidentialité	12
5.9	Sécurité des modèles	12
6	IA utilisée par les attaquants	13
6.1	Une capacité à double usage	13
6.2	Phishing automatisé et ingénierie sociale	13
6.3	Assistance à la reconnaissance	13
6.4	Génération de code et de contenu malveillant	13
6.5	Deepfakes et usurpation	14
6.6	Adaptation défensive	14
7	Éléments quantitatifs et comparaison des études	15
7.1	Principe d'interprétation	15
7.2	Comparaison des métriques	17
7.3	Lecture scientifique des résultats	19
8	Études de cas et tendances de recherche	21
8.1	Machine learning classique	21
8.2	Deep learning	21
8.3	Architectures hybrides	21
8.4	Analyse comportementale	21
8.5	AI-assisted SOC	22
8.6	Robustesse adversariale	22

8.7	IA explicable	22
8.8	Préservation de la confidentialité	22
8.9	Gouvernance de l'IA	22
8.10	Distinction entre preuve observée et hypothèse future	23
9	Conditions de déploiement digne de confiance	24
9.1	Gouvernance des données	24
9.2	Évaluation multi-dimensionnelle	24
9.3	Monitoring du modèle	24
9.4	Validation humaine	24
9.5	Sécurité du pipeline	24
9.6	Documentation et reproductibilité	25
10	Analyse transversale	26
10.1	L'IA transforme surtout la capacité d'analyse	26
10.2	Le benchmark n'est pas le terrain	26
10.3	La métrique dépend du risque	26
10.4	L'IA crée une boucle de dépendance	26
10.5	Une approche sociotechnique	26
11	Perspectives	28
11.1	Robustesse des systèmes d'IA	28
11.2	SOC assisté par IA	28
11.3	Collaboration humain-IA	28
11.4	IA explicable pour la cybersécurité	28
11.5	Apprentissage fédéré et confidentialité	28
11.6	Monitoring continu et dérive	29
11.7	Datasets de meilleure qualité	29
11.8	Évaluation cross-dataset	29
11.9	Gouvernance et standards	29
11.10	AI for Security + Security for AI	29
12	Conclusion	31
	Limites de cette étude	32
	Références	33
	Annexe — Note de traçabilité quantitative	35

Table des figures

2.1	Chaîne conceptuelle d'une détection de sécurité assistée par IA.	4
4.1	IA comme technologie d'augmentation des capacités du SOC.	9
5.1	Taxonomie conceptuelle des principaux risques d'un système d'IA appliqué à la cybersécurité.	12
6.1	Dynamique conceptuelle entre capacités d'IA, échelle des menaces et adaptation défensive.	14
7.1	Exactitude rapportée dans les études sélectionnées. Les résultats sont propres aux études et ne sont pas directement comparables entre datasets.	18
7.2	Précision, rappel et F1-score lorsque ces métriques sont disponibles.	18
7.3	Répartition des six études du corpus quantitatif par domaine d'application. Il s'agit d'un échantillon documentaire sélectionné, pas d'une distribution de la recherche mondiale.	19
7.4	Nombre d'études quantitatives par année de publication dans le corpus sélectionné. Cette distribution ne doit pas être interprétée comme une tendance globale de la littérature.	19
11.1	Cadre prospectif : AI for Security et Security for AI.	30

Liste des tableaux

3.1	Comparaison des principales applications de l'IA en cybersécurité.	7
7.1	Études quantitatives du corpus sélectionné.	16
7.2	Résultats détaillés de l'étude Dai et al. sur CIC-MalMem-2022.	17
7.3	Comparaison des métriques disponibles dans le corpus. Les valeurs absentes sont notées « — ».	17
8.1	Distinction méthodologique entre observations et perspectives.	23

CHAPITRE 1

Introduction et cadre de recherche

1.1 Contexte

La transformation numérique a multiplié les systèmes connectés, les services en ligne, les objets connectés, les infrastructures cloud et les flux de données. Cette interconnexion augmente la quantité d'événements techniques produits par les systèmes d'information : connexions, authentifications, flux réseau, journaux, fichiers, alertes de sécurité, événements applicatifs et signaux provenant de solutions de protection. Dans un centre opérationnel de sécurité, cette masse d'information doit être triée, corrélée et interprétée rapidement.

Le problème n'est pas seulement le volume. Les menaces évoluent, changent de caractéristiques et peuvent être difficiles à distinguer du comportement légitime. Les systèmes classiques fondés sur des signatures ou des règles restent utiles pour de nombreux cas connus, mais les approches d'apprentissage automatique offrent la possibilité d'apprendre des régularités statistiques dans des données de sécurité et de rechercher des écarts par rapport à ces régularités. Les revues de littérature soulignent cependant que les performances dépendent fortement des données, des caractéristiques, des métriques et du protocole d'évaluation [1, 12].

La Threat Landscape 2025 d'ENISA a analysé 4875 incidents observés entre le 1er juillet 2024 et le 30 juin 2025, illustrant l'ampleur du contexte opérationnel dans lequel les équipes de sécurité doivent hiérarchiser les événements [7]. En 2026, ENISA a également publié une nouvelle édition fondée sur les incidents observés en 2025 et continue d'identifier l'IA comme un facteur susceptible de soutenir des opérations malveillantes [8].

1.2 Problématique

La question centrale de cette recherche est :

Comment l'intelligence artificielle transforme-t-elle la détection et la prévention des cybermenaces, et quelles sont les limites et les nouveaux risques liés à son utilisation en cybersécurité ?

Cette formulation impose de considérer simultanément les bénéfices opérationnels et les risques induits. Une analyse limitée aux taux d'exactitude des modèles donnerait une vision incomplète, car un système de sécurité doit aussi être robuste, maintenable, explicable lorsque cela est nécessaire, adapté à son contexte et capable de fonctionner avec des données qui évoluent.

1.3 Objectifs

1.3.1 Objectif général

Analyser comment l'intelligence artificielle transforme la détection et la prévention des cybermenaces tout en évaluant ses limites techniques, ses risques opérationnels et ses perspectives futures.

1.3.2 Objectifs spécifiques

- Identifier les principales applications de l'IA en cybersécurité défensive ;
- comparer des approches documentées et leurs résultats quantitatifs ;
- examiner l'importance de la qualité des données, des métriques et de la généralisation ;
- analyser l'apprentissage automatique adversarial, l'empoisonnement des données et les attaques contre les systèmes d'IA ;
- étudier les usages offensifs de l'IA sous l'angle du risque cyber ;
- identifier les orientations de recherche et les défis de déploiement.

1.4 Questions de recherche

1. Quelles fonctions de cybersécurité sont transformées par l'IA ?
2. Quels bénéfices sont documentés ?
3. Quelles limites techniques et opérationnelles persistent ?
4. Quels nouveaux risques résultent de l'IA elle-même ?
5. Comment l'IA modifie-t-elle les capacités offensives en cybersécurité ?
6. Quelles conditions sont nécessaires à un déploiement digne de confiance ?

1.5 Périmètre et méthode

Cette étude est documentaire et analytique ; elle ne constitue pas une expérimentation originale en laboratoire. Le corpus quantitatif est volontairement sélectionné et ne prétend pas représenter l'ensemble de la littérature scientifique. Les résultats sont rapportés avec leur contexte expérimental afin d'éviter les généralisations abusives.

La méthode de synthèse repose sur quatre principes : (1) identifier la source ; (2) identifier le dataset et la tâche lorsqu'ils sont disponibles ; (3) conserver les métriques publiées sans remplacer les valeurs manquantes par zéro ; (4) séparer les observations publiées des interprétations et des hypothèses prospectives. Cette démarche est cohérente avec les préoccupations de fiabilité, de mesure et de gestion du risque mises en avant par NIST et ENISA [5, 14].

CHAPITRE 2

Fondements de l'IA et de la cybersécurité

2.1 Intelligence artificielle

L'intelligence artificielle désigne un ensemble de méthodes permettant à des systèmes informatiques de produire des sorties telles que des prédictions, classifications, recommandations ou contenus à partir d'objectifs définis. Dans le domaine de la cybersécurité, l'IA est principalement mobilisée pour analyser des données de sécurité, apprendre des relations complexes et assister la décision humaine.

2.2 Apprentissage automatique

Le machine learning (ML) regroupe des méthodes qui apprennent un modèle à partir de données. En cybersécurité, le modèle peut apprendre à distinguer des événements bénins et malveillants, à classer des familles de malware ou à repérer des comportements atypiques.

2.2.1 Apprentissage supervisé

Le modèle apprend à partir d'exemples associés à des étiquettes. Une tâche de classification peut, par exemple, utiliser des observations étiquetées « normal » et « attaque ». L'avantage est la possibilité d'évaluer directement la classification sur un jeu de test. La limite est la dépendance aux labels et à leur représentativité.

2.2.2 Apprentissage non supervisé et détection d'anomalies

Les approches non supervisées cherchent des structures sans dépendre nécessairement d'étiquettes exhaustives. Un autoencodeur peut apprendre à reconstruire un comportement considéré comme normal ; un écart de reconstruction peut ensuite servir de signal d'anomalie. Cette logique est particulièrement intéressante lorsque les événements malveillants rares ou inconnus sont difficiles à étiqueter.

2.2.3 Classification et détection d'anomalies

La classification répond à la question « à quelle classe appartient cet événement ? ». La détection d'anomalies répond plutôt à « cet événement s'écarte-t-il suffisamment du comportement appris ? ». En pratique, des architectures hybrides peuvent combiner les deux approches.

2.3 Deep learning

Le deep learning (DL) utilise des réseaux neuronaux comportant plusieurs couches de représentation. CNN, RNN, LSTM et architectures hybrides peuvent exploiter respectivement des motifs locaux, des dépendances séquentielles ou des représentations complexes. Une revue publiée dans IEEE Access en 2025 analyse 31 travaux de détection d'intrusion par deep learning et met en évidence, parmi les défis persistants, la qualité des données, la scalabilité, la robustesse adversariale, la confidentialité et l'interprétabilité [1].

2.4 IA générative

L'IA générative produit du contenu, par exemple du texte ou du code. En sécurité défensive, elle peut assister la synthèse d'incidents, la recherche dans une base documentaire ou la préparation d'analyses. Elle introduit également des risques : génération d'informations erronées, fuite de données confidentielles, mauvaise interprétation de sorties ou usage offensif par des acteurs malveillants. Le profil NIST consacré à l'IA générative fournit un cadre spécifique de gestion de ces risques [2].

2.5 Notions fondamentales de cybersécurité

La cybersécurité vise à protéger les systèmes, réseaux, applications et données contre les compromissions et perturbations. Dans ce rapport, les notions suivantes sont centrales :

IDS

Intrusion Detection System : système qui surveille des événements afin d'identifier des activités suspectes ou malveillantes.

SOC

Security Operations Center : organisation et ensemble d'outils chargés de surveiller, analyser et traiter les événements de sécurité.

SIEM

Security Information and Event Management : plateforme qui centralise et corrèle des journaux et événements provenant de plusieurs sources.

Threat intelligence

collecte, qualification et mise en contexte d'informations relatives aux menaces afin de soutenir la décision de sécurité.




Figure 2.1 – Chaîne conceptuelle d'une détection de sécurité assistée par IA.

Source : élaboration de l'auteur à partir des concepts de ML, IDS et SOC.

CHAPITRE 3

Applications de l'IA en cybersécurité

3.1 Détection d'intrusion

Les systèmes de détection d'intrusion peuvent exploiter des caractéristiques issues des flux réseau, des paquets, des journaux ou des comportements de systèmes. Les modèles supervisés peuvent classer des événements connus tandis que les autoencodeurs et autres méthodes d'anomalie cherchent des déviations. Telikani et al. combinent un autoencodeur et un SVM multitâche avec une stratégie sensible au coût afin de traiter notamment le déséquilibre des classes et les attaques peu fréquentes [15]. Leur évaluation sur UNSW-NB15 et BoT-IoT rapporte en moyenne 92,2% de rappel, 96,2% de précision et 94,3% de F1-score. Ces valeurs restent liées au protocole expérimental et aux jeux de données utilisés.

3.2 Détection de malware

La détection de malware peut exploiter une analyse statique, dynamique ou hybride. L'analyse statique observe des caractéristiques du fichier ou du programme sans nécessairement l'exécuter ; l'analyse dynamique observe son comportement pendant l'exécution. L'approche hybride cherche à tirer parti des deux sources.

L'étude de Shah, Shah, Soni, Vadhavana et Patel sur TUANDROMD compare KNN, SVM et arbre de décision et rapporte respectivement 97,65%, 98,62% et 99,10% d'exactitude [11]. Ces résultats ne constituent pas un classement universel des algorithmes de détection de malware : ils décrivent le protocole et le dataset de cette étude.

3.3 Détection du phishing

Le phishing peut être étudié à partir d'URLs, de caractéristiques lexicales, de structures de pages Web ou d'informations comportementales. Un classifieur peut apprendre des différences statistiques entre sites légitimes et sites malveillants.

Une étude publiée en 2024 dans le cadre d'UBMK évalue six algorithmes sur le dataset UCI Phishing Websites. Pour Random Forest, elle rapporte 96,7% d'exactitude, 96,1% de précision, 98,2% de rappel et 97,1% de F1-score [3]. La conclusion doit rester limitée à ce protocole : la performance d'un modèle sur UCI Phishing Websites ne permet pas d'inférer automatiquement sa performance sur de nouvelles campagnes de phishing.

3.4 Analyse comportementale

L'analyse comportementale vise à modéliser des séquences ou profils d'activité afin d'identifier des écarts significatifs. Elle peut concerner les utilisateurs, les sessions, les processus, les connexions ou les interactions avec les ressources.

Mohan et Kumar proposent un système d'IDS combinant SVM et un Voting Classifier basé sur Random Forest et régression logistique, avec des caractéristiques comportementales temporelles. Sur CICIDS2017, l'étude rapporte 98,8% d'exactitude et 98,7% de F1-score [9]. Une autre étude publiée en 2026 combine 1D-CNN, Bi-LSTM et autoencodeur pour une détection d'anomalies comportementales et rapporte 98,1% d'exactitude, 97,9% de précision, 98,3% de rappel et 98,1% de F1-score [13]. Dans ce dernier cas, le nom précis du dataset n'est pas suffisamment établi dans les métadonnées consultées pour être complété ici : il est donc indiqué comme indisponible dans le tableau quantitatif.

3.5 SOC et SIEM

Dans un SOC, l'IA peut intervenir avant même qu'un analyste examine une alerte. Elle peut contribuer à la corrélation de plusieurs événements, à la déduplication, au regroupement d'incidents similaires, à la classification et à la priorisation. Dans un SIEM, elle peut aider à rechercher des relations dans de grandes quantités de journaux et à réduire le temps consacré aux opérations répétitives.

Cette assistance ne signifie pas que l'analyste disparaît. Les décisions à fort impact doivent rester associées à une validation humaine, particulièrement lorsque les données sont ambiguës ou que la conséquence d'une erreur est importante. Le rôle de l'IA est donc mieux décrit comme une augmentation des capacités humaines que comme un remplacement universel.

3.6 Threat intelligence

L'IA peut assister l'extraction d'informations depuis des rapports, la classification d'indicateurs, le regroupement de signaux et la mise en relation d'observations. Elle peut ainsi accélérer la transformation de données hétérogènes en informations exploitables. Toutefois, les sorties générées doivent être vérifiées : une extraction incorrecte ou une corrélation erronée peut propager une conclusion fausse dans la chaîne de décision.

Table 3.1 – Comparaison des principales applications de l'IA en cybersécurité.

Application	Données typiques	Technique IA	Objectif principal	Limitation principale
Détection d'intrusion	Flux réseau, paquets, logs	SVM, arbres, autoencodeurs, DL	Identifier des activités anormales ou malveillantes	Généralisation entre environnements et évolution du trafic
Malware	Fichiers, permissions, API, traces d'exécution	Classification, DL, ensembles	Classer un programme comme bénin ou malveillant	Évolution des familles et évacion
Phishing	URL, page Web, caractéristiques lexicales/structurelles	RF, SVM, DL	Identifier les sites/messages suspects	Nouvelles campagnes et changement de caractéristiques
Comportement	Sessions, événements utilisateurs/processus	Anomalie, LSTM, autoencodeur	Détecter les écarts comportementaux	Définition du comportement normal et faux positifs
SOC/SIEM	Alertes, journaux, incidents	Corrélation, classification, GenAI	Prioriser et assister l'investigation	Qualité des logs et validation humaine
Threat intelligence	Rapports, indicateurs, textes	NLP, classification, extraction	Extraire et relier des informations	Ambiguïté, erreurs d'extraction et contexte

Source : synthèse documentaire de l'auteur ; voir notamment [1, 5, 12].

CHAPITRE 4

Bénéfices de l'IA en cybersécurité

4.1 Automatisation

Une capacité importante de l'IA est d'automatiser des opérations répétitives : classification initiale d'alertes, enrichissement de contexte, regroupement d'événements ou recherche de motifs. L'objectif n'est pas de supprimer la supervision, mais de réserver davantage de temps humain aux situations complexes.

4.2 Scalabilité

Lorsque le volume de données augmente, l'analyse manuelle de chaque événement devient difficile. Un modèle peut traiter automatiquement une grande quantité d'observations selon une procédure uniforme. La scalabilité dépend toutefois des coûts de calcul, de l'architecture d'infrastructure et du temps nécessaire à l'entraînement et à la maintenance.

4.3 Vitesse de détection

Une détection automatisée peut réduire le temps entre l'apparition d'un signal et son classement initial. Cette vitesse est utile lorsque la fenêtre d'intervention est courte. Elle ne garantit toutefois pas une réponse correcte : une alerte très rapide mais mal classée peut augmenter le coût opérationnel.

4.4 Reconnaissance de motifs

Les modèles peuvent identifier des relations multidimensionnelles difficiles à formaliser par des règles simples. Cette propriété explique leur intérêt dans des contextes où les comportements malveillants se manifestent par des combinaisons de caractéristiques plutôt que par une signature unique.

4.5 Détection d'anomalies

L'anomalie est particulièrement pertinente lorsque les défenseurs ne disposent pas d'une liste complète des menaces à rechercher. Les architectures hybrides peuvent apprendre le comportement normal et utiliser un classifieur pour différencier plusieurs catégories d'événements.

4.6 Priorisation des alertes

Dans un SOC, le nombre d'alertes peut dépasser la capacité d'analyse immédiate des équipes. Un système d'IA peut attribuer une priorité ou regrouper des alertes. Cette fonction doit cependant être accompagnée d'une stratégie de contrôle des faux négatifs, car une priorisation erronée peut faire passer un incident important derrière des événements moins critiques.

4.7 Surveillance continue et assistance aux analystes

L'IA est adaptée à une surveillance continue lorsque les données arrivent à intervalles réguliers. Elle peut assister les analystes en proposant des regroupements, des hypothèses ou des résumés. Elle ne dispose pas nécessairement du contexte organisationnel complet et doit donc être considérée comme un composant d'un système sociotechnique plus large.




Figure 4.1 – IA comme technologie d'augmentation des capacités du SOC.

Source : élaboration de l'auteur.

CHAPITRE 5

Limites et risques

5.1 Faux positifs

Un faux positif correspond à un événement légitime classé comme suspect. Dans un SOC, son coût n'est pas seulement statistique : il peut produire une surcharge d'alertes, une fatigue analytique, des investigations inutiles et une perte de confiance dans l'outil. La performance d'un système doit donc être appréciée en fonction du coût opérationnel des erreurs, et pas uniquement d'une métrique globale.

5.2 Faux négatifs

Un faux négatif correspond à une menace non détectée. En cybersécurité, ce type d'erreur peut être particulièrement critique lorsqu'il concerne une compromission persistante ou une activité à fort impact. Le rappel, la sensibilité et l'analyse de la matrice de confusion sont donc importants pour compléter l'exactitude.

5.3 Qualité des données

Les modèles apprennent à partir de données. Des données incomplètes, bruitées, anciennes ou biaisées peuvent produire un système qui reflète mal le contexte réel. Le déséquilibre des classes est fréquent en sécurité : les événements malveillants peuvent être beaucoup moins nombreux que les événements bénins. Telikani et al. ont précisément intégré une stratégie sensible au coût pour traiter le problème de classes peu représentées [15].

La qualité doit également être comprise comme une propriété du cycle de vie. Un dataset historiquement représentatif peut devenir moins pertinent lorsque les applications, réseaux, utilisateurs et techniques d'attaque changent.

5.4 Généralisation

Un modèle peut obtenir un excellent score sur un jeu de test tout en perdant en performance dans un autre environnement. Cette difficulté est particulièrement importante en cybersécurité car les infrastructures, distributions de trafic et types de menaces diffèrent. Les revues récentes de NIDS mettent en avant la nécessité de mieux évaluer la généralisation et la robustesse au-delà des benchmarks isolés [1].

5.5 Explicabilité

Certains modèles complexes produisent une prédiction sans fournir une justification facilement interprétable. Or un analyste peut avoir besoin de comprendre pourquoi un événement est classé comme suspect avant d'isoler une machine ou de déclencher une réponse. L'explicabilité doit donc être adaptée au contexte : elle ne signifie pas nécessairement rendre le modèle mathématiquement simple, mais fournir des éléments permettant d'évaluer et de contrôler sa décision.

5.6 Biais

Un biais peut apparaître dans les données, les labels, le choix des caractéristiques, la sélection des événements ou l'architecture du modèle. En cybersécurité, un biais peut conduire à une surdétection de certains comportements ou à une sous-détection d'autres. Le contrôle du biais nécessite des évaluations segmentées, des tests sur plusieurs sources et une surveillance continue.

5.7 Apprentissage automatique adversarial

Le machine learning adversarial étudie les attaques destinées à tromper, perturber ou compromettre les systèmes d'apprentissage. Le rapport NIST AI 100-2e2025 distingue notamment les attaques d'évasion, d'empoisonnement, de confidentialité et de mauvaise utilisation selon les systèmes concernés [16]. L'enjeu est double : protéger les modèles utilisés pour défendre les infrastructures et empêcher qu'un modèle de sécurité soit manipulé de manière à diminuer sa capacité de détection.

5.7.1 Évasion

Une attaque d'évasion cherche conceptuellement à modifier l'entrée présentée au modèle afin d'obtenir une prédiction incorrecte, sans nécessairement modifier le processus d'apprentissage. En sécurité, cela peut correspondre à la recherche de caractéristiques qui permettent à une activité malveillante de ressembler statistiquement à une activité légitime.

5.7.2 Poisoning

L'empoisonnement intervient au niveau des données utilisées pour l'apprentissage ou la mise à jour. Des données manipulées peuvent influencer le modèle et provoquer des comportements incorrects. Oprea, Singhal et Vassilev soulignent que la sécurité des modèles doit être étudiée avant leur déploiement dans des contextes critiques [10].

5.7.3 Attaques de confidentialité et manipulation de modèle

Les systèmes d'IA peuvent également exposer des informations sensibles par des mécanismes de fuite ou d'inférence, ou être compromis par des modifications non autorisées. La sécurité doit donc couvrir les données, les paramètres, les interfaces, les dépendances logicielles et les pipelines de déploiement.

5.8 Confidentialité

Les données de cybersécurité peuvent contenir des adresses IP, identifiants, traces d'activité, contenus de journaux ou informations sur les utilisateurs. Leur centralisation dans un pipeline d'IA augmente la surface de données à protéger. Le principe de minimisation, le contrôle d'accès, la segmentation et la gouvernance des données deviennent donc importants.

5.9 Sécurité des modèles

Lorsqu'une organisation dépend d'un modèle pour prendre une décision de sécurité, ce modèle devient un actif critique. Il doit être protégé contre l'accès non autorisé, la modification, la substitution, la fuite de données d'entraînement et les dépendances compromises. ENISA souligne la nécessité de considérer la cybersécurité de l'IA elle-même, et notamment les questions de données, de tests et de traçabilité [5, 6].




Figure 5.1 – Taxonomie conceptuelle des principaux risques d'un système d'IA appliqué à la cybersécurité.

Source : élaboration de l'auteur, structurée à partir des risques décrits par NIST et ENISA [6, 14, 16].

CHAPITRE 6

IA utilisée par les attaquants

6.1 Une capacité à double usage

L'IA est une technologie à double usage. Les mêmes capacités générales qui peuvent aider un analyste à résumer des informations ou automatiser une classification peuvent être utilisées pour augmenter l'échelle et la rapidité d'activités malveillantes. Le Threat Landscape 2025 d'ENISA indique que l'IA est utilisée pour faciliter ou renforcer certaines activités offensives et que la disponibilité de systèmes d'IA augmente la capacité de mise à l'échelle des activités malveillantes [7].

6.2 Phishing automatisé et ingénierie sociale

Les modèles génératifs peuvent faciliter la production de contenus textuels plus adaptés au contexte d'une cible, y compris pour des campagnes de phishing ou d'usurpation. L'intérêt pour l'attaquant est principalement une réduction du coût de production et une augmentation du volume potentiel. La défense doit donc renforcer la détection comportementale, l'authentification forte et la vérification hors bande plutôt que compter uniquement sur des caractéristiques linguistiques.

6.3 Assistance à la reconnaissance

L'IA peut aider à organiser des informations publiques, à résumer des documents ou à corréler des observations. Cette capacité augmente potentiellement la vitesse de préparation d'une opération. Le rapport ENISA 2025 décrit plus largement l'utilisation de l'IA comme multiplicateur de capacités dans l'écosystème de menace [7].

6.4 Génération de code et de contenu malveillant

Les modèles de génération de code peuvent réduire certaines barrières techniques, notamment pour produire ou transformer du code. Dans une perspective défensive, cette évolution augmente l'importance de l'analyse automatisée, de la revue de code, de l'isolation des environnements et du contrôle des usages des modèles. Ce rapport ne fournit pas de procédures ni de code permettant de conduire une attaque.

6.5 Deepfakes et usurpation

Les techniques génératives peuvent également être utilisées pour produire des contenus audio, vidéo ou visuels imitant une personne. Le risque est particulièrement pertinent pour l'ingénierie sociale et la fraude. La réponse doit intégrer des contrôles organisationnels : authentification multicanale, vérification indépendante des demandes sensibles et politiques de séparation des responsabilités.

6.6 Adaptation défensive

L'évolution des capacités offensives ne signifie pas que les défenseurs sont nécessairement dépassés. Elle implique une adaptation du modèle de défense : davantage de contrôle continu, meilleure observabilité, modèles évalués dans des conditions adversariales, validation humaine et protection du pipeline d'IA.




Figure 6.1 – Dynamique conceptuelle entre capacités d'IA, échelle des menaces et adaptation défensive.

Source : élaboration de l'auteur ; analyse défensive fondée notamment sur ENISA [7].

CHAPITRE 7

Éléments quantitatifs et comparaison des études

7.1 Principe d'interprétation

Cette section est centrale pour la traçabilité du rapport. Les chiffres ne sont pas agrégés en une note globale et ne servent pas à établir un classement universel des modèles. Une exactitude de 99% sur un dataset donné n'est pas directement comparable à une exactitude de 97% obtenue sur un autre dataset, car les tâches, distributions, classes, protocoles de séparation et définitions d'« attaque inconnue » peuvent différer.

Les études ci-dessous sont donc présentées selon neuf dimensions : étude, année, dataset, tâche, modèle, métrique, résultat, limitation et source.

Table 7.1 – Études quantitatives du corpus sélectionné.

ID	Ann.	Domaine / étude	Dataset	Modèle	Métriques	Résultat clé	Limitation
1	2024	IDS — Telikani et al.	UNSW-NB15 + BoT-IoT	Autoencodeur + SVM multitâche sensible au coût	Rappel, précision, F1	92,2% ; 96,2% ; 94,3%	Résultats liés aux datasets et au protocole ; ne constituent pas une performance universelle.
2	2025	Malware Android — Shah et al.	TUANDROMD	KNN / SVM / arbre de décision	Exactitude	97,65% ; 98,62% ; 99,10%	Comparaison propre au dataset et au protocole ; ne permet pas de classer universellement les algorithmes.
3	2024	Phishing — UBMK	UCI Phishing Websites	Random Forest	Exactitude, précision, rappel, F1	96,7% ; 96,1% ; 98,2% ; 97,1%	Résultats spécifiques au dataset UCI et au protocole expérimental.
4	2025	IDS comportemental — Mohan et Kumar	CICIDS2017	SVM + Voting (RF + LR)	Exactitude, F1	98,8% ; 98,7%	Benchmark spécifique ; généralisation et déploiement réel à confirmer.
5	2026	Anomalies comportementales — Singh et al.	Non disponible dans les métadonnées vérifiées	1D-CNN + Bi-LSTM + autoencodeur	Exactitude, précision, rappel, F1	98,1% ; 97,9% ; 98,3% ; 98,1%	Benchmark spécifique ; dataset non identifié de façon suffisamment fiable ici ; coût et généralisation à étudier.
6	2024	Attaques inédites — Dai et al.	CIC-MalMem-2022	RF + AE ; XGBoost + AE	Exactitude, précision, rappel, F1, MCC	Voir Tableau 7.2	Snapshot spécifique du paysage malware ; cross-dataset nécessaire.

Source : sources primaires : [3, 4, 9, 11, 13, 15].

Table 7.2 – Résultats détaillés de l’étude Dai et al. sur CIC-MalMem-2022.

Modèle / protocole	Accuracy	Precision	Recall	F1	MCC
Random Forest + Autoencoder, données inédites	99,9892%	100%	99,9803%	99,9901%	99,8313%
XGBoost + Autoencoder, données inédites	99,9741%	100%	99,9533%	99,9976%	99,8002%

Source : Dai et al., PLOS ONE, 2024 [4].

Le terme « données inédites » doit être lu conformément à la méthodologie de Dai et al. : l’étude définit l’inconnu à partir de données non rencontrées pendant l’entraînement et discute également la différence entre nouvelles attaques et variations d’attaques connues [4]. Ces résultats ne prouvent donc pas que les modèles détectent toutes les attaques zero-day réelles.

7.2 Comparaison des métriques

Table 7.3 – Comparaison des métriques disponibles dans le corpus. Les valeurs absentes sont notées « — ».

Étude / modèle	Accuracy	Precision	Recall	F1	MCC
Telikani et al. 2024	—	96,2%	92,2%	94,3%	—
Soni et al. — KNN	97,65%	—	—	—	—
Soni et al. — SVM	98,62%	—	—	—	—
Soni et al. — arbre	99,10%	—	—	—	—
Phishing — RF	96,7%	96,1%	98,2%	97,1%	—
Mohan & Kumar 2025	98,8%	—	—	98,7%	—
Singh et al. 2026	98,1%	97,9%	98,3%	98,1%	—
Dai — RF-AE inédit	99,9892%	100%	99,9803%	99,9901%	99,8313%
Dai — XGB-AE inédit	99,9741%	100%	99,9533%	99,9976%	99,8002%

Source : corpus quantitatif vérifié ; absence d’une métrique = information non rapportée dans la synthèse retenue, pas une valeur nulle.




Figure 7.1 – Exactitude rapportée dans les études sélectionnées. Les résultats sont propres aux études et ne sont pas directement comparables entre datasets.




Figure 7.2 – Précision, rappel et F1-score lorsque ces métriques sont disponibles.




Figure 7.3 – Répartition des six études du corpus quantitatif par domaine d’application. Il s’agit d’un échantillon documentaire sélectionné, pas d’une distribution de la recherche mondiale.




Figure 7.4 – Nombre d’études quantitatives par année de publication dans le corpus sélectionné. Cette distribution ne doit pas être interprétée comme une tendance globale de la littérature.

7.3 Lecture scientifique des résultats

Plusieurs observations peuvent être formulées sans transformer les chiffres en classement. Premièrement, les études présentent des performances élevées sur leurs protocoles respectifs. Deuxièmement, les métriques ne sont pas toutes disponibles pour tous les travaux. Troisièmement, l’étude Dai et al. montre l’intérêt potentiel d’une combinaison entre détection d’anomalies et classification sur une définition expérimentale de données inédites, tout en reconnaissant que le dataset représente un instantané spécifique et que des validations inter-datasets sont nécessaires [4].

Enfin, la comparaison révèle pourquoi l’exactitude seule est insuffisante. Dans une classe rare, un système peut atteindre une exactitude élevée tout en manquant une partie des attaques. Le

rappel, la précision, le F1-score et, lorsqu'il est disponible, le MCC fournissent des perspectives complémentaires. La bonne pratique consiste donc à interpréter plusieurs métriques avec la matrice de confusion, la distribution des classes et la méthode de séparation des données.

CHAPITRE 8

Études de cas et tendances de recherche

8.1 Machine learning classique

Les modèles tels que Random Forest, SVM, régression logistique, KNN et arbres de décision restent présents dans les travaux de cybersécurité. Leur intérêt vient notamment de leur coût de calcul souvent inférieur à celui de certaines architectures profondes, de leur maturité et de leur capacité à fournir des baselines compréhensibles.

8.2 Deep learning

Le deep learning est utilisé lorsque les relations entre caractéristiques sont complexes ou que les données sont séquentielles. Les architectures hybrides, comme CNN + LSTM ou autoencodeur + classifieur, cherchent à combiner plusieurs propriétés. La littérature récente sur les NIDS montre cependant que la complexité du modèle ne résout pas automatiquement les problèmes de données, de généralisation ou de robustesse [1].

8.3 Architectures hybrides

Les études Telikani et Dai illustrent deux formes d'hybridation. Dans le premier cas, l'autoencodeur contribue à la représentation et le SVM à la classification, avec un traitement du déséquilibre et des tâches multiples. Dans le second, l'autoencodeur sert à identifier des anomalies avant de combiner cette information avec Random Forest ou XGBoost [4, 15]. L'hybridation est donc une stratégie de conception, pas une garantie de performance universelle.

8.4 Analyse comportementale

Les travaux comportementaux cherchent à exploiter le contexte temporel et les séquences d'activité. L'étude de Mohan et Kumar utilise notamment des caractéristiques telles que les habitudes d'accès et les historiques de commandes [9]. Cette orientation répond à une limite des systèmes qui considèrent seulement des caractéristiques statiques.

8.5 AI-assisted SOC

La tendance vers des SOC assistés par IA combine plusieurs fonctions : détection, corrélation, résumé, enrichissement et aide à l'investigation. La question de recherche n'est plus seulement « quel modèle obtient le meilleur score ? », mais « comment intégrer le modèle dans une chaîne de décision fiable ? ». Cela rapproche la recherche ML de sujets de gouvernance, d'interface homme-machine, de validation et de monitoring.

8.6 Robustesse adversariale

La sécurité du modèle devient une composante à part entière. NIST propose une taxonomie structurée des attaques adversariales, couvrant notamment évasion, empoisonnement, confidentialité et mauvaise utilisation selon les familles de systèmes [16]. Cette taxonomie facilite l'établissement de plans de test plus complets.

8.7 IA explicable

L'explicabilité vise à rendre les décisions suffisamment interprétables pour qu'un humain puisse les examiner. En cybersécurité, elle est particulièrement utile lorsqu'une décision entraîne une action disruptive. Les futures recherches devront donc combiner performance statistique et utilité opérationnelle.

8.8 Préservation de la confidentialité

Les approches fédérées ou privacy-preserving cherchent à réduire la nécessité de centraliser certaines données sensibles. Elles peuvent cependant introduire des coûts de communication, des risques de poisoning et des contraintes de gouvernance. ENISA identifie la sécurité et la confidentialité parmi les dimensions à traiter dans la recherche sur l'IA et la cybersécurité [5].

8.9 Gouvernance de l'IA

Le NIST AI RMF fournit une structure de gestion des risques destinée aux organisations qui conçoivent, déploient ou utilisent des systèmes d'IA [14]. L'intérêt pour la cybersécurité est de compléter l'évaluation purement technique par des mécanismes de gouvernance, de mesure, de cartographie et de gestion des risques.

8.10 Distinction entre preuve observée et hypothèse future

Table 8.1 – Distinction méthodologique entre observations et perspectives.

Catégorie	Exemple dans ce rapport	Statut
Preuve observée	Une étude rapporte 98,8% d'exactitude sur CICIDS2017	Résultat publié, lié à son protocole
Interprétation prudente	L'analyse comportementale peut fournir des signaux complémentaires aux caractéristiques statiques	Synthèse analytique ; dépend du contexte
Perspective	Les SOC pourraient intégrer davantage de contrôle continu des modèles	Hypothèse / orientation future, non prédiction

Source : élaboration de l'auteur selon les règles de traçabilité de l'étude.

CHAPITRE 9

Conditions de déploiement digne de confiance

9.1 Gouvernance des données

Avant l'entraînement, l'organisation doit savoir quelles données sont collectées, pourquoi, avec quelles autorisations et pendant combien de temps elles sont conservées. Les labels doivent être documentés et les transformations de données reproductibles. Les jeux de données utilisés pour les tests doivent être séparés de manière à limiter les fuites d'information.

9.2 Évaluation multi-dimensionnelle

Un protocole sérieux doit considérer plusieurs métriques et plusieurs conditions. Lorsque c'est possible, il est utile de tester un modèle sur des périodes temporelles distinctes, des environnements différents ou des datasets externes. La validation inter-datasets est particulièrement importante pour évaluer la généralisation.

9.3 Monitoring du modèle

Un modèle déployé n'est pas figé. La distribution des données peut évoluer : nouveaux logiciels, nouveaux comportements, nouvelles campagnes de phishing, nouvelles familles de malware. Le monitoring doit donc détecter la dérive des données et la baisse de performance.

9.4 Validation humaine

La validation humaine est particulièrement importante pour les décisions à fort impact. Une architecture raisonnable peut déléguer à l'IA le tri initial et conserver à l'analyste le contrôle des actions irréversibles ou perturbatrices.

9.5 Sécurité du pipeline

Le pipeline doit être protégé depuis la collecte jusqu'au déploiement : accès aux données, stockage des modèles, dépendances, registres, API, interfaces d'administration et mécanismes de mise à jour. Les risques de poisoning et de substitution de modèles doivent être considérés dès la conception [10, 16].

9.6 Documentation et reproductibilité

Une étude ou un système devrait documenter au minimum : dataset, version, période de collecte, prétraitements, caractéristiques, modèle, hyperparamètres pertinents, protocole de séparation, métriques, limites et environnement de calcul. Cette discipline permet d'éviter les conclusions qui ne peuvent pas être reproduites.

CHAPITRE 10

Analyse transversale

10.1 L'IA transforme surtout la capacité d'analyse

Les éléments étudiés convergent vers une transformation de la capacité à traiter l'information. L'IA n'introduit pas une nouvelle fonction magique de cybersécurité ; elle modifie la manière dont certaines fonctions existantes sont exécutées. La détection devient davantage fondée sur des modèles statistiques, l'investigation peut être assistée par des corrélations et la priorisation peut être automatisée.

10.2 Le benchmark n'est pas le terrain

La différence entre benchmark et environnement réel constitue l'un des résultats méthodologiques les plus importants. Un dataset est une représentation du phénomène étudié. Il ne reproduit pas nécessairement la totalité des systèmes, utilisateurs, réseaux et attaques d'une organisation. Les résultats de Telikani, phishing, Mohan et Dai doivent donc être lus dans leurs contextes respectifs [3, 4, 9, 15].

10.3 La métrique dépend du risque

Dans un contexte de phishing, le rappel peut être prioritaire si manquer une campagne est très coûteux. Dans une fonction de monitoring très volumineuse, une précision faible peut générer une surcharge. Le choix des métriques doit donc correspondre au coût des erreurs et au processus métier.

10.4 L'IA crée une boucle de dépendance

Plus un SOC dépend d'un modèle, plus la qualité et la disponibilité de ce modèle deviennent importantes. Cela transforme l'IA en actif critique. La cybersécurité doit donc protéger non seulement l'environnement surveillé par l'IA, mais aussi l'IA elle-même.

10.5 Une approche sociotechnique

La performance opérationnelle dépend de l'interaction entre modèle, données, analystes, procédures, infrastructure et gouvernance. Un modèle excellent peut devenir peu utile si les alertes

ne sont pas intégrées aux workflows. Inversement, un modèle moins spectaculaire statistiquement peut être utile s'il est stable, explicable et bien intégré.

CHAPITRE 11

Perspectives

11.1 Robustesse des systèmes d'IA

Les futurs travaux devront mieux tester les systèmes contre des entrées adversariales, des données bruitées et des changements de distribution. La robustesse doit devenir une propriété évaluée explicitement, au même titre que l'exactitude.

11.2 SOC assisté par IA

Les architectures de SOC pourraient combiner modèles spécialisés, moteurs de corrélation, recherche documentaire et modèles génératifs. La priorité scientifique sera de garantir la traçabilité des sorties, la validation des sources et la possibilité pour l'analyste de reprendre le contrôle.

11.3 Collaboration humain-IA

Le modèle le plus réaliste pour de nombreux usages de sécurité est une collaboration : l'IA traite une partie du volume, identifie des signaux et prépare des informations ; l'humain apporte le contexte organisationnel, le jugement et la responsabilité de la décision.

11.4 IA explicable pour la cybersécurité

L'objectif ne doit pas être de rendre tous les modèles parfaitement transparents, mais de fournir des explications adaptées au risque. Les recherches peuvent étudier les méthodes permettant de justifier une alerte, de montrer les caractéristiques déterminantes et d'indiquer l'incertitude du modèle.

11.5 Apprentissage fédéré et confidentialité

Les approches fédérées peuvent réduire la centralisation de données sensibles. Elles nécessitent néanmoins des mécanismes de sécurité contre l'empoisonnement, des protocoles de communication robustes et une gouvernance claire des participants.

11.6 Monitoring continu et dérive

La surveillance du modèle doit devenir une fonction opérationnelle. Un système devrait pouvoir signaler lorsque la distribution des données s'éloigne de celle observée pendant l'entraînement ou lorsque les métriques diminuent.

11.7 Datasets de meilleure qualité

Une priorité de recherche est le développement de jeux de données plus représentatifs, documentés, diversifiés et régulièrement actualisés. La littérature récente sur les NIDS souligne que la qualité des données et la validation externe restent des problèmes ouverts [1].

11.8 Évaluation cross-dataset

La validation sur plusieurs datasets est une méthode directe pour tester la généralisation. L'étude Dai et al. indique elle-même la nécessité d'évaluer des datasets supplémentaires et de conduire des validations inter-datasets [4].

11.9 Gouvernance et standards

Les organisations auront besoin de méthodes communes pour documenter les données, tester les modèles et gérer les incidents liés à l'IA. ENISA souligne notamment les besoins en terminologie standardisée, métriques fiables, procédures de test et traçabilité des données [6]. Le NIST AI RMF constitue une référence structurante pour la gestion des risques de systèmes d'IA [14].

11.10 AI for Security + Security for AI

Cette formulation résume la double direction du domaine.

- **AI for Security** : utiliser l'IA pour détecter, classer, corréler, prioriser et assister la réponse aux menaces.
- **Security for AI** : protéger les données, modèles, infrastructures, interfaces et chaînes de développement de l'IA contre la manipulation, la fuite et les attaques adversariales.

Ces deux dimensions sont indissociables. Une organisation qui utilise une IA très performante pour protéger ses systèmes mais ne sécurise pas le modèle ou ses données d'entraînement crée une nouvelle dépendance exploitable. Inversement, une politique de sécurité de l'IA sans capacité d'utiliser efficacement l'IA pour traiter le volume des événements peut limiter le bénéfice opérationnel de la technologie.




Figure 11.1 – Cadre prospectif : AI for Security et Security for AI.

Source : élaboration de l'auteur, en cohérence avec les axes de recherche d'ENISA et la gestion des risques NIST [5, 14, 16].

CHAPITRE 12

Conclusion

La question de recherche était : *Comment l'intelligence artificielle transforme-t-elle la détection et la prévention des cybermenaces, et quelles sont les limites et les nouveaux risques liés à son utilisation en cybersécurité ?*

L'analyse documentaire montre que l'IA transforme principalement la capacité à traiter de grandes quantités de données de sécurité, à rechercher des motifs complexes, à détecter des anomalies, à classer des événements et à assister les analystes. Les domaines concernés couvrent la détection d'intrusion, le malware, le phishing, l'analyse comportementale, les SOC/SIEM et la threat intelligence.

Les résultats quantitatifs sélectionnés montrent des performances élevées dans plusieurs études. Cependant, ces performances sont inséparables de leurs datasets, tâches et protocoles. Les résultats de Telikani et al., de l'étude sur TUANDROMD, de l'étude de phishing, de Mohan et Kumar, de Singh et al. et de Dai et al. doivent donc être interprétés comme des résultats expérimentaux contextualisés [3, 4, 9, 11, 13, 15]. Ils ne démontrent ni une supériorité universelle d'un algorithme, ni la capacité d'un modèle à détecter toutes les menaces réelles.

Les limites identifiées sont nombreuses : qualité et représentativité des données, déséquilibre des classes, faux positifs, faux négatifs, généralisation, explicabilité, biais, coût de calcul, dérive des données, confidentialité et sécurité du modèle. L'apprentissage automatique adversarial ajoute une catégorie de risques spécifique : un système d'IA destiné à protéger une infrastructure peut lui-même être ciblé. NIST formalise notamment les notions d'évasion, d'empoisonnement et d'attaques de confidentialité dans sa taxonomie récente [16], tandis que les travaux sur le poisoning rappellent que la sécurité des modèles doit être étudiée avant les déploiements critiques [10].

L'IA modifie également la menace elle-même. Les capacités génératives et analytiques peuvent faciliter le phishing, l'ingénierie sociale, la préparation d'opérations et la production de contenus malveillants. ENISA observe cette évolution et souligne le potentiel de mise à l'échelle des activités malveillantes permises par la disponibilité des systèmes d'IA [7].

Ainsi, l'IA ne supprime pas les problèmes de cybersécurité : elle déplace une partie du problème vers la qualité des données, la robustesse des modèles, l'intégration opérationnelle et la sécurité du pipeline d'IA. Son utilisation doit être accompagnée de validation humaine, de monitoring, de tests adversariaux, de gouvernance et de mécanismes de sécurité.

La conclusion structurante de cette étude est donc la suivante : la cybersécurité de demain doit développer simultanément **AI for Security** et **Security for AI**. La première dimension exploite l'IA pour augmenter les capacités de défense ; la seconde protège les systèmes d'IA contre les erreurs, les manipulations, les fuites et les attaques. C'est l'articulation de ces deux

dimensions, plutôt que la recherche d'un score de benchmark maximal, qui constitue une base plus robuste pour un déploiement responsable et durable.

Limites de cette étude

Le présent rapport ne constitue pas une méta-analyse statistique de la littérature mondiale. Le corpus quantitatif est volontairement limité aux études spécifiées et vérifiées pour cette production. Une étude future pourrait élargir le corpus, formaliser des critères d'inclusion/exclusion, effectuer une revue systématique, comparer des datasets communs et reproduire les protocoles expérimentaux dans un environnement contrôlé.

Références

- [1] F. M. ANIS, M. ALABDULLATIF, S. ALJBLI et M. HAMMOUDEH, « A Survey on the Applications of Deep Learning in Network Intrusion Detection Systems to Enhance Network Security, » *IEEE Access*, t. 13, p. 185 357-185 373, 2025. DOI : [10.1109/ACCESS.2025.3624952](https://doi.org/10.1109/ACCESS.2025.3624952). adresse : <https://doi.org/10.1109/ACCESS.2025.3624952>.
- [2] C. AUTIO et al., « Artificial Intelligence Risk Management Framework : Generative Artificial Intelligence Profile, » National Institute of Standards et Technology, rapp. tech. NIST AI 600-1, 2024. DOI : [10.6028/NIST.AI.600-1](https://doi.org/10.6028/NIST.AI.600-1). adresse : <https://doi.org/10.6028/NIST.AI.600-1>.
- [3] A. AYYAR et al., « Comparative Analysis and Practical Implementation of Machine Learning Algorithms for Phishing Website Detection, » in *2024 9th International Conference on Computer Science and Engineering (UBMK)*, 2024. DOI : [10.1109/UBMK63289.2024.10773479](https://doi.org/10.1109/UBMK63289.2024.10773479). adresse : <https://doi.org/10.1109/UBMK63289.2024.10773479>.
- [4] Z. DAI et al., « An intrusion detection model to detect zero-day attacks in unseen data using machine learning, » *PLOS ONE*, t. 19, n° 9, e0308469, 2024. DOI : [10.1371/journal.pone.0308469](https://doi.org/10.1371/journal.pone.0308469). adresse : <https://doi.org/10.1371/journal.pone.0308469>.
- [5] EUROPEAN UNION AGENCY FOR CYBERSECURITY, « Artificial Intelligence and Cybersecurity Research, » ENISA, rapp. tech., 2023. adresse : <https://www.enisa.europa.eu/publications/artificial-intelligence-and-cybersecurity-research>.
- [6] EUROPEAN UNION AGENCY FOR CYBERSECURITY, « Cybersecurity of AI and Standardisation, » ENISA, rapp. tech., 2023. DOI : [10.2824/277479](https://doi.org/10.2824/277479). adresse : <https://doi.org/10.2824/277479>.
- [7] EUROPEAN UNION AGENCY FOR CYBERSECURITY, « ENISA Threat Landscape 2025, » ENISA, rapp. tech., 2025. adresse : <https://www.enisa.europa.eu/publications/enisa-threat-landscape-2025>.
- [8] EUROPEAN UNION AGENCY FOR CYBERSECURITY, « ENISA Threat Landscape 2026, » ENISA, rapp. tech., 2026. adresse : <https://www.enisa.europa.eu/topics/cyber-threats/threat-landscape>.
- [9] J. MOHAN et M. R. KUMAR, « Intelligent Intrusion Detection System Combining Behavioral Analysis and Machine Learning Methods, » in *2025 3rd International Conference on Data Science and Network Security (ICDSNS)*, 2025. DOI : [10.1109/ICDSNS65743.2025.11168668](https://doi.org/10.1109/ICDSNS65743.2025.11168668). adresse : <https://doi.org/10.1109/ICDSNS65743.2025.11168668>.
- [10] A. OPREA, A. SINGHAL et A. VASSILEV, « Poisoning Attacks against Machine Learning : Can Machine Learning be Trustworthy ? » *Computer*, t. 55, n° 11, p. 94-99, 2022. DOI : [10.1109/MC.2022.3190787](https://doi.org/10.1109/MC.2022.3190787). adresse : <https://doi.org/10.1109/MC.2022.3190787>.

-
- [11] H. SHAH, V. SHAH, N. SONI, V. VADHAVANA et K. PATEL, « A Comparative Analysis for Android Malware Detection Using Machine Learning Models, » in *2025 6th International Conference on Mobile Computing and Sustainable Informatics (ICMCSI)*, 2025. DOI : [10.1109/ICMCSI64620.2025.10883385](https://doi.org/10.1109/ICMCSI64620.2025.10883385). adresse : <https://doi.org/10.1109/ICMCSI64620.2025.10883385>.
 - [12] K. SHAUKAT, S. LUO, V. VARADHARAJAN, I. A. HAMEED et M. XU, « A Survey on Machine Learning Techniques for Cyber Security in the Last Decade, » *IEEE Access*, t. 8, p. 222 310-222 354, 2020. DOI : [10.1109/ACCESS.2020.3041951](https://doi.org/10.1109/ACCESS.2020.3041951). adresse : <https://doi.org/10.1109/ACCESS.2020.3041951>.
 - [13] V. SINGH, A. PARVEZ, R. KRISHNAMOORTHY, H. DEVANNA, K. SRIDEVI et V. B. GUJAR, « An Intelligent Behavioral Anomaly Detection Framework for Next-Generation Digital Forensics Using Hybrid Deep Learning and Context-Aware Feature Fusion, » in *2026 4th International Conference on Artificial Intelligence and Machine Learning Applications Theme : Healthcare and Internet of Things (AIMLA)*, 2026. DOI : [10.1109/AIMLA67915.2026.11522297](https://doi.org/10.1109/AIMLA67915.2026.11522297). adresse : <https://doi.org/10.1109/AIMLA67915.2026.11522297>.
 - [14] E. TABASSI, « Artificial Intelligence Risk Management Framework (AI RMF 1.0), » National Institute of Standards et Technology, rapp. tech. NIST AI 100-1, 2023. DOI : [10.6028/NIST.AI.100-1](https://doi.org/10.6028/NIST.AI.100-1). adresse : <https://doi.org/10.6028/NIST.AI.100-1>.
 - [15] A. TELIKANI et al., « A Cost-Sensitive Machine Learning Model With Multitask Learning for Intrusion Detection in IoT, » *IEEE Transactions on Industrial Informatics*, t. 20, n° 3, p. 3880-3890, 2024. DOI : [10.1109/TII.2023.3314208](https://doi.org/10.1109/TII.2023.3314208). adresse : <https://doi.org/10.1109/TII.2023.3314208>.
 - [16] A. VASSILEV, A. OPREA, A. FORDYCE, H. ANDERSON, X. DAVIES et M. HAMIN, « Adversarial Machine Learning : A Taxonomy and Terminology of Attacks and Mitigations, » National Institute of Standards et Technology, rapp. tech. NIST AI 100-2e2025, 2025. DOI : [10.6028/NIST.AI.100-2e2025](https://doi.org/10.6028/NIST.AI.100-2e2025). adresse : <https://doi.org/10.6028/NIST.AI.100-2e2025>.

Annexe — Note de traçabilité quantitative

Pour faciliter la reproductibilité, les valeurs quantitatives de ce rapport ont été conservées avec leur unité et leur contexte. Une valeur absente dans une publication n’a pas été reconstruite à partir d’une autre métrique. Les termes « accuracy », « precision », « recall », « F1-score » et « MCC » sont conservés dans leur sens usuel ; leurs valeurs ne sont pas converties en score global.

- Les résultats Telikani et al. sont rapportés comme des moyennes sur UNSW-NB15 et BoT-IoT selon la publication [15].
- Les résultats Android sont rapportés séparément pour KNN, SVM et arbre de décision sur TUANDROMD [11].
- Les résultats de phishing concernent Random Forest sur le dataset UCI Phishing Websites [3].
- Les résultats de Mohan et Kumar concernent CICIDS2017 et une architecture SVM + Voting Classifier [9].
- Les résultats comportementaux de 2026 sont conservés tels que publiés ; le nom du dataset est explicitement laissé indisponible dans ce rapport faute de métadonnée vérifiée suffisante [13].
- Les résultats « unseen » de Dai et al. sont ceux obtenus sur le protocole de données inédites défini par les auteurs sur CIC-MalMem-2022 [4].